

Peyronnet Théo
Chifflet Gabriel
Racot Nicolas
Athoumani Nourâne
Rodrigues Amorim Daniel



IUT de Vélizy-Rambouillet
CAMPUS DE VÉLIZY-VILLACOUBLAY

SAE 3.01

Développement d'une application

Documentation Statistiques

Sommaire

Partie n°1 : Introduction.....	3
Rôle et importance des statistiques.....	3
Partie n°2 : Présentation des statistiques.....	4
Stat1.R.....	4
Stat2.R.....	4
Stat3.R.....	4
Stat4.R.....	4
Partie n°3 : Utilité / Importance.....	5
Statistique 1.....	5
Statistique 2.....	5
Statistique 3.....	5
Statistique 4.....	5
Partie n°4 : Technique.....	6
Statistique 1 - Annexe 4.....	6
Statistique 2 - Annexe 5.....	6
Statistique 4 - Annexe 7.....	7
Partie n°5 : Statistiques sur les logs.....	8
Annexe.....	9
Annexe 1 : Génération d'un graphique avec Stat2.R.....	9
Annexe 2 : Dashboard de présentation des informations générales sur l'activité.....	9
Annexe 3 : Exemple de résultat des statistiques sur les logs.....	10
Annexe 4 : Code Statistique 1.....	11
Annexe 5 : Code Statistique 2.....	12
Annexe 6 : Code Statistique 3.....	13
Annexe 7 : Code Statistique 4.....	14

Partie n°1 : Introduction

Rôle et importance des statistiques

Pour vérifier l'état du parc ainsi que celui de la plateforme sur laquelle il est hébergé, les techniciens et les administrateurs ont besoin de statistiques. Ces dernières vont leur permettre non seulement de maintenir mais aussi de prévoir et adapter les besoins du site

4 statistiques seront générées à partir des fichiers “**connections.csv**”, “**inventory_devices.csv**” et “**inventory_monitors2.csv**”. Chacune d'entre elles est instanciée par une fonction elle-même contenu séparément dans un fichier **.R** qui lui est propre.

Après analyse statistique on obtient donc :

- Stat1.R
- Stat2.R
- Stat3.R
- Stat4.R

Lien vers le github : [Fichiers de statistiques sur Github](#)

Partie n°2 : Présentation des statistiques

Stat1.R

Cette statistique basée sur **"inventory_devices.csv"** nous renvoie le pourcentage d'Unités Centrales (UC) (sur un site) répondant aux exigences passées en paramètres. Elle inclut aussi l'utilisation d'une loi binomiale afin d'estimer la probabilité d'obtenir au moins **n** UC "ok" sur un échantillon (ex : une salle de TP).

Stat2.R

Toujours basée sur le même fichier csv, cette fois, la statistique génère un graphique. Elle permet de prévoir les fins de garanties des UC du parc sur une période passée en paramètre.

De plus, il a été choisi de séparer dans le graphique les fins de garanties en fonction des marques des UC et on obtient donc un résultat similaire à l'[annexe 1](#). L'utilisation de la librairie ggplot2 est indispensable pour obtenir un tel rendu.

Stat3.R

Dans ce fichier, la statistique se concentre sur l'analyse des connexions des utilisateurs avec le fichier **"connections.csv"**.

Nous donnons en paramètre un nombre de palier qui permettent de regrouper les données en plusieurs groupes. Alors on calcule la moyenne du temps de connexion cumulé pour chaque utilisateur et on en fait la moyenne. Il suffit ensuite de compter le nombre de résultats obtenus au niveau de chaque palier et nous obtenons un tableau nous permettant de consulter les tendances de l'ensemble des utilisateurs.

Stat4.R

Dans cette dernière statistique s'appuyant sur une fusion des données des fichiers **"inventory_devices.csv"** et **"inventory_monitors2.csv"** nous cherchons à savoir combien il existe d'écrans de grandes tailles (27 pouces) attribués à des UC qui pourtant ne sont pas très puissants. Ici l'indicateur utilisé pour juger si un UC est puissant est sa RAM.

Alors on compte lorsqu'un pc possède un seuil de RAM inférieur à celui indiqué en paramètre et une taille d'écran supérieure ou égale au seuil fourni en paramètre et on rentre ses informations dans un nouveau fichier csv.

Partie n°3 : Utilité / Importance

Comme expliqué précédemment, chaque statistique a pour but d'aider les techniciens et/ou les administrateurs.

Statistique 1

L'utilité de cette statistique est qu'elle permet facilement au technicien de repérer s'il y a un surplus de matériel vieillissant et obsolète dont les capacités sont inférieures aux besoins.

Il possède alors un indicateur fiable lui permettant de déterminer si une grande portion du parc doit être renouvelée ou non.

Statistique 2

Ici aussi, le but est d'avoir un indicateur servant de prévention au technicien. Anticiper la fin de certaines garanties dans le but de remplacer les matériels des marques les plus marqués en priorités ou alors de voir quel marque joindre en priorité afin d'obtenir des extensions de garanties avant qu'il ne soit trop tard.

En clair, cette statistique permet d'empêcher le parc de devenir à risque au dernier moment sans que personne ne l'ait vu venir.

Statistique 3

Les informations concernant les temps de connexions intéressent surtout l'administrateur web. Dans notre cas, calculer le temps moyen de connexion de chaque utilisateur nous permet de pouvoir identifier de potentiels temps de connexions anormales.

Par exemple, puisque l'on constate que la plupart des temps moyens de connexions tournent autour de 1h, si l'administrateur constate une session de 5h il serait fort probable que l'utilisateur soit en réalité inactif. Ou encore, si une session dispose d'un temps moyen de connexion de seulement quelques minutes, il se peut que le compte soit inactif ou plus utilisé.

Statistique 4

Avec cette statistique un technicien peut plus facilement repérer des postes incohérents. Il peut conserver des écrans plus grands et donc plus coûteux à des usages plus adaptés au lieu de les brider avec des UC incapables de les exploiter à leur plein potentiel. Il peut également savoir quels sont les UC ayant besoin d'une amélioration de la RAM.

Partie n°4 : Technique

Dans l'ensemble des scripts on utilise une fonction afin de pouvoir faire varier les paramètres des statistiques et obtenir une flexibilité sur la génération des statistiques. De plus, dans la totalité des fichiers on utilise **read.csv2()** (ou **read.csv()**) qui est la méthode la plus couramment utilisée afin de lire le contenu d'un fichier csv dont le chemin d'accès est toujours renseigné en paramètre.

Dans la suite de cette partie nous expliquerons plus en détail le contenu

Statistique 1 - Annexe 4

Elle est initiée par 6 paramètres dont le paramètres utilisés pour la loi binomiale et les seuils minimums utilisés pour déterminer si un UC correspond au minimum requis.

Dans la fonction, on cherche tout d'abord à sélectionner seulement les UC du site spécifié en paramètre avant d'obtenir la part de pc répondant aux exigences renseignées. Il ne reste plus qu'à faire usage de **pbinom()** pour user de la loi binomiale qui nous servira de résultat final.

Statistique 2 - Annexe 5

Dans cette fonction 3 paramètres sont utilisés avec notamment la date de début de l'analyse et sa période.

La particularité de cette fonction réside dans l'utilisation de la librairie ggplot2. On va alors extraire les dates de fin de garanties du fichier csv en sélectionnant la colonne correspondante. Ensuite, il est possible de les filtrer dans le but de garder seulement celles correspondant à la période souhaitée. Enfin, on utilise **ggplot()** pour générer un graphique (avec les données de la période), **geom_bar()** pour générer les barres et les rendre proportionnels à la part qu'occupe chaque groupe et les autres fonctions assurent surtout un embellissement pour rendre le graphique plus agréable visuellement.

Statistique 3 - Annexe 6

La fonction aggregate nous permet de calculer la moyenne du temps de connexion de chaque utilisateur (Chaque utilisateur apparaît 2 fois dans le fichier **connexions.csv**). Nous pouvons ensuite créer une échelle allant de la valeur minimale à la valeur maximale en la divisant en un nombre de paliers renseignés en paramètres. Il suffit ensuite d'ajouter chaque moyenne dans le palier qui lui correspond pour générer un data frame.

Statistique 4 - Annexe 7

On réalise une fusion entre 2 fichiers csv en mettant en commun la colonne NAME de **inventory_devices.csv** et ATTACHED_TO de **inventory_monitors2.csv** avec la fonction **merge()** qui est l'équivalent en R du JOIN en SQL. On peut ensuite sélectionner les configurations en dessous d'un seuil spécifié de RAM mais au-dessus du seuil renseigné de la taille d'écran. On enregistre les postes concernés et on renvoie leur nombre.

Partie n°5 : Statistiques sur les logs

Voici la vue SQL qui permet de calculer les informations statistiques sur la relation des logs des actions des techniciens.


```
-- RECAP LOGS MENSUEL
29 CREATE OR REPLACE VIEW vw_month_activity AS
30 WITH monthly_field_activity AS (
31     SELECT
32         DATE_FORMAT(log_date, '%Y-%m') AS mois,
33         field_updated,
34         COUNT(*) AS nb_modifications,
35         COUNT(DISTINCT serial_number) AS nb_devices,
36         COUNT(DISTINCT login) AS nb_utilisateurs
37     FROM device_logs
38     GROUP BY DATE_FORMAT(log_date, '%Y-%m'), field_updated)
39 SELECT
40     mois,
41     field_updated,
42     nb_modifications,
43     nb_devices,
44     nb_utilisateurs,
45     -- Classement des champs les plus modifiés par mois (Numérotation)
46     DENSE_RANK() OVER (PARTITION BY mois ORDER BY nb_modifications DESC) AS month_rank,
47     -- Classement global (Numérotation)
48     RANK() OVER (ORDER BY nb_modifications DESC) AS global_rank,
49     -- Permet de savoir si un champ est dans le top X% des modifications du mois
50     -- Reçoit un score de 1 à 4 (1 = top 25% des champs les plus modifiés du mois)
51     NTILE(4) OVER (PARTITION BY mois ORDER BY nb_modifications DESC) AS quartile_mois,
52     -- Évolution vs mois précédent (Lag permet de prendre le résultat du mois précédent)
53     nb_modifications - LAG(nb_modifications) OVER (PARTITION BY field_updated ORDER BY mois) AS evolution_vs_last_month,
54     -- Évolution en pourcentage par rapport au mois précédent
55     ROUND(
56         (nb_modifications - LAG(nb_modifications) OVER (PARTITION BY field_updated ORDER BY mois))
57         / NULLIF(LAG(nb_modifications) OVER (PARTITION BY field_updated ORDER BY mois), 0) * 100,
58         2
59     ) AS evolution_pct
60 FROM monthly_field_activity
61 ORDER BY mois DESC, month_rank;
```

Un exemple de résultat en Annexe 3 (logs sur 3 mois, 2024-11 est le tout premier mois de collecte de log d'où les *null*).


La clause *WITH* permet de calculer une sous requête sur laquelle les statistiques vont être calculées. La sous requête donne par mois et attribut manipulé (os, disk, location, ...), le nombre de modification (insertion, modification, suppression), le nombre de machine unique modifié et le nombre de technicien unique ayant agit ce mois par type de champs.

Le *SELECT* renvoie à partir des calculs fait dans le *WITH* l'ensemble de ces informations (les 5 premier attribut du *SELECT*). La description de chaque ligne est faite en commentaire dans le code.

Annexe



Annexe 1 : Génération d'un graphique avec Stat2.R



Annexe 2 : Dashboard de présentation des informations générales sur l'activité

mois	field_updated	nb_modifications	nb_devices	nb_utilisateurs	month_rank	global_rank	quartile_mois	evolution_vs_last_month	evolution_pct
2025-01	monitor	3	3	2	1	1	1	1	50.00
2025-01	attached_to_computer	2	2	1	2	6	1	0	0.00
2025-01	computer	1	1	1	3	14	1	-1	-50.00
2025-01	cpu	1	1	1	3	14	2	0	0.00
2025-01	disk_gb	1	1	1	3	14	2	0	0.00
2025-01	location	1	1	1	3	14	2	0	0.00
2025-01	os_name	1	1	1	3	14	3	0	0.00
2025-01	ram_mb	1	1	1	3	14	3	0	0.00
2025-01	room	1	1	1	3	14	4	0	0.00
2025-01	state	1	1	1	3	14	4	0	0.00
2024-12	attached_to_computer	2	2	1	1	6	1	-1	-33.33
2024-12	computer	2	2	2	1	6	1	-1	-33.33
2024-12	monitor	2	2	2	1	6	1	-1	-33.33
2024-12	building	1	1	1	2	14	2	0	0.00
2024-12	disk_gb	1	1	1	2	14	2	0	0.00
2024-12	location	1	1	1	2	14	3	0	0.00
2024-12	os_name	1	1	1	2	14	3	0	0.00
2024-12	ram_mb	1	1	1	2	14	4	0	0.00
2024-12	room	1	1	1	2	14	4	0	0.00
2024-11	attached_to_computer	3	3	2	1	1	1	NULL	NULL
2024-11	computer	3	3	2	1	1	1	NULL	NULL
2024-11	monitor	3	3	2	1	1	1	NULL	NULL
2024-11	state	1	1	1	3	14	2	NULL	NULL
2024-11	building	1	1	1	3	14	2	NULL	NULL
2024-11	cpu	1	1	1	3	14	2	NULL	NULL

Annexe 3 : Exemple de résultat des statistiques sur les logs

```

1 # Renvoie la probabilité d'avoir n PC correspondant aux exigences passés en paramètres
2 # dans un échantillon de taille k
3
4 proba_binomial <- function(fichier, ville, taille_salle, minimum_ok, minimum_ram, minimum_disk) {
5
6   donnees <- read.csv2(fichier, sep = ",")
7
8   donnees_ville <- donnees[donnees$LOCATION == ville, ]
9
10  total <- nrow(donnees_ville)
11  reussite <- sum(donnees_ville$RAM_MB ≥ minimum_ram & donnees_ville$DISK_GB ≥ minimum_disk)
12  moy_ok <- reussite / total
13
14  resultat_probabilite <- round(pbinom(minimum_ok - 1,
15                                     size = taille_salle,
16                                     prob = moy_ok,
17                                     lower.tail = FALSE) * 100, 2)
18
19  taux_ok = round(moy_ok * 100, 2)
20  ligne1 <- paste("Analyse faites sur la totalité du site de :", ville)
21  ligne2 <- paste("Taux de PC OK sur le site :", taux_ok, "%")
22  ligne3 <- paste("Probabilité d'avoir au moins", minimum_ok, "PC prêts sur", taille_salle, ":")
23  ligne4 <- paste(resultat_probabilite, "%")
24
25  mon_rapport <- c(ligne1, ligne2, ligne3, ligne4)
26
27  print(mon_rapport)
28  return(resultat_probabilite)
29 }
30
31 proba_binomial("inventory_devices.csv", "Rambouillet", 20, 15, 8192, 256)
32

```

Annexe 4 : Code Statistique 1

```

1 # Génère un graphique permettant de prévoir pour chaque mois
2 # le nombre de fin de garanties à partir d'une date
3
4 library(ggplot2)
5
6 graphique_garantie ← fonction(fichier, date_debut, nb_mois) {
7
8   donnees ← read.csv2(fichier, sep = ",")
9
10  donnees$WARRANTY_END ← as.Date(donnees$WARRANTY_END)
11
12  date_debut_obj ← as.Date(date_debut)
13  date_fin_obj ← seq(date_debut_obj, length = 2, by = paste(nb_mois, "months"))[2]
14
15  filtre_dates ← donnees$WARRANTY_END ≥ date_debut_obj & donnees$WARRANTY_END ≤ date_fin_obj
16  donnees_selection ← donnees[filtre_dates, ]
17
18  donnees_selection$Mois_Annee ← format(donnees_selection$WARRANTY_END, "%Y-%m")
19
20  graphique ← ggplot(donnees_selection, aes(x = Mois_Annee, fill = MANUFACTURER)) +
21    geom_bar() +
22    scale_fill_manual(values = c("Dell" = "#9C51B6", "HP" = "#005FFF", "Lenovo" = "#E00000")) +
23    labs(
24      title = paste("Fins de garantie sur", nb_mois, "mois"),
25      subtitle = paste("À partir de :", date_debut),
26      x = "Mois d'échéance",
27      y = "Nombre d'actifs",
28      fill = "Constructeur"
29    ) +
30    theme_minimal() +
31    # Incline les dates sur l'échelle x (sinon c'est illisible)
32    theme(axis.text.x = element_text(angle = 45, hjust = 1))
33
34  print(graphique)
35 }
36
37 graphique_garantie("inventory_devices.csv", "2026-01-01", 18)

```

Annexe 5 : Code Statistique 2

```

1 # Renvoie un dataframe indiquant le nombre de connexion dont le temps
2 # d'activité (en minutes) correspond à un palier
3
4 moyennes_connexions <- function(fichier, nombre_paliers) {
5
6   donnees = read.csv(fichier, sep = ",")
7
8   stats_moyennes = aggregate(duration_seconds ~ login,
9                               data = donnees,
10                              FUN = mean)
11   stats_moyennes$moyenne_min = stats_moyennes$duration_seconds / 60
12
13   val_min = min(stats_moyennes$moyenne_min)
14   val_max = max(stats_moyennes$moyenne_min)
15
16   pas = (val_max - val_min) / nombre_paliers
17
18   paliers = c()
19   valeurs = c()
20
21   for (i in 1:nombre_paliers) {
22     borne_basse = val_min + (i - 1) * pas
23     borne_haute = val_min + i * pas
24     effectif <- sum(stats_moyennes$moyenne_min ≥ borne_basse & stats_moyennes$moyenne_min ≤ borne_haute)
25     paliers[i] = round(borne_basse, 0)
26     valeurs[i] = effectif
27   }
28
29   affichage = data.frame(
30     Palier = paliers,
31     Effectif = valeurs
32   )
33
34   return(affichage)
35 }
36
37 moyennes_connexions("connections.csv", 10)

```

Annexe 6 : Code Statistique 3

```

1 #Cette statistique nous donne le nombre de PC jugée "faible" (par rapport à la RAM)
2 #associés à des écrans considérés trop grands
3 alerte_ecran_pc ← fonction(fichier_pc, fichier_echans, seuil_max_ram, seuil_mini_ecran) {
4
5   pc = read.csv(fichier_pc, sep = ",")
6   echans = read.csv(fichier_echans, sep = ",")
7
8   donnees_fusionnees = merge(pc, echans, by.x = "NAME", by.y = "ATTACHED_TO")
9
10  incoherences = donnees_fusionnees[
11    donnees_fusionnees$RAM_MB < seuil_max_ram &
12    donnees_fusionnees$SIZE_INCH ≥ seuil_mini_ecran,
13  ]
14
15  nbre_incoherences = nrow(incoherences)
16
17  # On crée un fichier csv conservant la liste des UC concernés (et leur site)
18  postes_concernes = incoherences[, c("NAME", "RAM_MB", "SIZE_INCH", "LOCATION")]
19  write.csv(postes_concernes, file = "list_monitor_device.csv", row.names = F)
20
21  cat("Nombre de grands écrans associés à un PC pas assez puissant :", nbre_incoherences, "\n")
22
23  return(nbre_incoherences)
24 }
25
26 alerte_ecran_pc("inventory_devices.csv", "inventory_monitors2.csv", 16384, 27)

```

Annexe 7 : Code Statistique 4